Data-Driven Retail: Cómo revertir una caída de ingresos del 82% mediante Market Basket Analysis

Caso de Estudio: La Cesta Verde

Gerard Camós Moratalla

Marzo 2026

Rol: Business & Data Analyst

Proyecto: La Cesta Verde

Sector: Retail Alimentario / Gran Consumo

Stack Tecnológico: SQL (SQLite) | Python (Pandas - Google Colab) | Power BI | Excel

LinkedIn

1. RESUMEN EJECUTIVO (VISIÓN DE NEGOCIO)

Contexto del Proyecto: Este análisis estratégico se desarrolla para la empresa **La Cesta Verde**, una distribuidora minorista de alimentación que, a pesar de gestionar un volumen de negocio anual cercano a los **40 millones de euros**, presentaba señales de alerta críticas en su estructura de ingresos.

El Desafío: El proyecto nace de la necesidad de diagnosticar y revertir una **caída libre en la facturación mensual**, la cual sufrió un desplome del **82%** a lo largo del ejercicio (de 6,7M € en enero a 1,1M € en diciembre). Mi misión fue liderar la transición de un modelo de gestión basado en "intuición" hacia un modelo de **Decisiones Basadas en Datos (Data-Driven Decisions)**.

Objetivos Estratégicos:

- **Diagnóstico de Fugas:** Identificar mediante SQL las causas de la pérdida de ingresos y la excesiva dependencia de ciertos departamentos (donde uno solo acumulaba el 93% de las ventas).
- **Optimización del Ticket Medio:** Incrementar el valor promedio por pedido (**19,34 €**) mediante un modelo de probabilidad en Python para detectar hábitos de consumo.
- **Estandarización del Reporting:** Sustituir procesos manuales por un ecosistema interactivo en Power BI que permita a la dirección monitorizar la salud del negocio en tiempo real.

Valor Aportado: La intervención no solo proporcionó visibilidad sobre los riesgos de concentración de mercado, sino que entregó una **hoja de ruta operativa** basada en 399 reglas de asociación de productos, permitiendo pasar de una fase de "supervivencia" a una de "crecimiento optimizado" mediante el uso de analítica avanzada.

2. DIAGNÓSTICO DEL PROBLEMA (ANÁLISIS DE RIESGOS)

Antes de iniciar la fase de modelado, se realizó un diagnóstico exhaustivo para entender la naturaleza de la crisis de ingresos. El análisis reveló una estructura de ventas altamente vulnerable basada en tres factores críticos:

2.1. Análisis de la Volatilidad de Ingresos

La tendencia mensual mostró una degradación constante de la facturación. El negocio comenzó el año con una posición sólida de **6,67M €**, pero experimentó una contracción media mensual del **15%**, cerrando el ejercicio en **1,18M €**.

- **Riesgo Detectado:** La falta de una estrategia de retención de clientes y la posible estacionalidad no gestionada provocaron una pérdida del **82% del flujo de caja** operativo en 12 meses.

2.2. Concentración Crítica de Ventas (Efecto Pareto Extremo)

Mediante la segmentación por departamentos y secciones, se descubrió una dependencia alarmante:

- **Dependencia de Departamento:** El **Departamento 4** generó **37M €** de los 39,8M € totales. Esto significa que el **93% de la estabilidad de la empresa** dependía de una sola unidad de negocio.

- **Concentración en Secciones:** Las secciones 24, 123 y 83 representaron el **92% de los ingresos**. Cualquier cambio en la demanda o problemas de suministro en estas categorías específicas tendría un impacto sistémico en la compañía.

2.3. Diagnóstico del Ticket Medio (AOV)

A pesar de tener una base masiva de **2.060.188 pedidos**, el valor promedio de compra se situó en **19,34 €**.

- **Insight de Negocio:** El análisis sugirió que, aunque el volumen de transacciones era alto, los clientes utilizaban la plataforma para compras de "conveniencia" o artículos sueltos, desaprovechando el potencial de la cesta de la compra completa. La ausencia de un sistema de recomendaciones impedía maximizar el *Share of Wallet* del cliente.

2.4. Matriz de Dependencia de Producto

El catálogo presentaba una dependencia crítica de los productos orgánicos (Bananas y Fresas Orgánicas liderando con más de **4M de unidades conjuntas**). Si bien esto indicaba una fortaleza en una categoría, revelaba una incapacidad estructural para dar salida al resto de las **3.800 referencias** disponibles, aumentando el riesgo de obsolescencia de stock en otras secciones.

3. FASE TÉCNICA I: AUDITORÍA Y EXTRACCIÓN (SQL)

La base del proyecto fue la extracción y validación de datos provenientes de la tabla maestra ‘tickets’. Utilicé **SQLite** para procesar más de **2 millones de registros**, asegurando que los KPIs financieros fueran precisos antes de proceder al modelado.

3.1. Validación de la Integridad del Dato

El primer paso fue confirmar que las métricas macro coincidieran con los estados financieros de la empresa.

-- Cálculo del ingreso total anual y volumen de pedidos y clientes

```
SELECT
    SUM(precio_total) AS ingresos_totales,
    COUNT(DISTINCT id_pedido) AS total_pedidos,
    COUNT(DISTINCT id_cliente) AS total_clientes
FROM tickets;
```

-- Resultado: 39.854.875,32 € | 2.060.188 pedidos | 181.903 clientes.

3.2. Análisis de la Concentración de Ingresos (Pareto)

Para cuantificar el riesgo de dependencia detectado en el diagnóstico, ejecuté consultas de agregación por categorías.

-- Identificación de departamentos críticos

```
SELECT id_departamento, SUM(precio_total) AS ventas_departamento

FROM tickets

GROUP BY id_departamento

ORDER BY ventas_departamento DESC;
```

-- Insight: El Dept. 4 generó el 93% de la facturación (37.003.251,70 €).

3.3. Análisis de Tendencias Temporales

Para entender la velocidad de la caída de ingresos, utilicé funciones de fecha para agrupar la facturación por meses.

-- Evolución mensual para detectar puntos de inflexión

```
SELECT strftime('%Y-%m', fecha) AS mes, SUM(precio_total) AS ingreso_mensual

FROM tickets

GROUP BY mes

ORDER BY mes;
```

-- Evidencia: Descenso progresivo de 6,6M € (Enero) a 1,1M € (Diciembre).

3.4. Auditoría de Comportamiento del Cliente

Finalmente, analicé el gasto medio para entender si el problema era el número de clientes o el valor de sus cestas.

-- Cálculo del valor promedio por pedido (Ticket Medio)

```
SELECT AVG(venta_pedido) AS ticket_medio

FROM (

    SELECT id_pedido, SUM(precio_total) AS venta_pedido

    FROM tickets

    GROUP BY id_pedido

);
```

-- Resultado: 19,34 €. Un valor bajo que justifica la necesidad del modelo de asociación.

4. FASE TÉCNICA II: CIENCIA DE DATOS Y MODELADO (PYTHON)

Para abordar el bajo ticket medio (**19,34 €**), implementé un modelo de **Market Basket Analysis** (Análisis de la Cesta de la Compra). El objetivo fue identificar reglas de asociación entre productos para diseñar estrategias de *cross-selling* basadas en datos estadísticos, no en intuiciones.

4.1. Preprocesamiento y Estructuración de Datos

El mayor reto técnico fue transformar una base de datos relacional de **2,06 millones de líneas** en una matriz de transacciones apta para algoritmos de asociación.

- **Proceso:** Utilicé la librería **Pandas** para agrupar los productos por id_pedido y transformarlos mediante técnicas de *One-Hot Encoding*.
- **Resultado:** Una matriz dispersa donde cada fila representaba un pedido único y cada columna uno de los productos del catálogo, permitiendo un análisis computacional eficiente.

4.2. El Modelo Estadístico: Métricas de Valor

No me limité a ver qué productos se compraban más, sino que calculé la fuerza de su relación mediante tres métricas clave:

1. **Soporte:** Popularidad relativa de un producto. (Ej: La **Banana** está presente en una parte masiva de los pedidos).
2. **Confianza:** La probabilidad de que un cliente compre el "Producto B" dado que ya tiene el "Producto A" en la cesta.
3. **Lift (Correlación):** La métrica determinante. Un **Lift > 1** indica que la relación entre dos productos es una asociación real y no fruto del azar.

4.3. Hallazgos de Alto Impacto (Insights)

Tras procesar **399 reglas de asociación**, identifiqué patrones de consumo con un **Lift superior a 2.5**, lo que representa oportunidades de oro para el marketing:

- **Asociación de Frescos:** El **Cilantro Orgánico** y la **Cebolla Roja Orgánica** obtuvieron un **Lift de 3,60**.
    - *Acción sugerida:* Crear packs de "Receta de Ensalada/Guacamole" o ubicarlos adyacentes en el e-commerce.
- **Asociación de Snacks Saludables:** El **Hummus Original** y las **Zanahorias Baby Orgánicas** mostraron un **Lift de 2,50**.
    - *Acción sugerida:* Promoción de "Segundo producto al 50%" para fomentar el incremento del ticket medio.

4.4. Activos de Datos y Automatización de Decisiones

El script final consolidó las **399 reglas de asociación** en un archivo estructurado (reglas.csv), enriquecido con metadatos de secciones e identificadores de departamento. Este activo de datos no es solo un reporte, sino el motor de inteligencia que impulsa las siguientes utilidades:

- **Input para el Force-Directed Graph:** Este archivo permite la construcción del gráfico de red interactivo en Power BI. Al mapear las relaciones entre "antecedentes" y "consecuentes", el grafo permite visualizar la arquitectura de consumo de la empresa, donde el grosor de las conexiones (basado en el **Lift**) identifica instantáneamente los productos con mayor sinergia comercial.

- **Estrategia de Cross-Selling Automatizada:** Sirve como base para personalizar el envío de *Newsletters* y recomendaciones en el e-commerce. Si un cliente adquiere un producto "ancla", el sistema sugiere automáticamente su par con mayor confianza estadística.

- **Optimización Logística (Slotting):** Las reglas de asociación permiten rediseñar el *layout* del almacén. Ubicar físicamente cerca los productos que el modelo identifica con alta probabilidad de compra conjunta reduce drásticamente los tiempos de *picking* y los costes operativos de preparación de pedidos.

- **Gestión del Mix de Ventas:** Facilita la creación de "combos" o promociones cruzadas para combatir la **hiperconcentración** en productos orgánicos, incentivando la rotación de las 3.800 referencias con menor visibilidad pero alta afinidad detectada.

5. FASE TÉCNICA III: VISUALIZACIÓN ESTRATÉGICA (POWER BI)

El último eslabón del proyecto fue la creación de un ecosistema de reporting interactivo de dos páginas. El objetivo fue transformar las 399 reglas de asociación y los 2 millones de tickets en una herramienta de consulta ágil para la toma de decisiones.

5.1. Dashboard de Control Operativo (Pág. 1)

Diseñado para la monitorización diaria del rendimiento de **La Cesta Verde**.

- **Cuadro de Mando Superior (Scorecard):** Ubicación estratégica de 4 KPIs maestros para una lectura inmediata**: Ventas Totales (39,8M €), Clientes Únicos (181.903), Ticket Medio por Cliente y Ticket Medio por Pedido.**
- **Navegación y Filtrado Dinámico:** Implementación de barras segmentadoras (horizontal para **Meses** y vertical para **Categoría de Producto**) que permiten realizar análisis granulares en segundos.
- **Análisis de Tendencias y Eficiencia:** Un gráfico de columnas muestra la **Evolución de Ventas**, haciendo visible la caída del 82% detectada en SQL.
    - Inclusión de dos **Medidores (Gauges)** críticos: *"Productos diferentes por pedido"* y *"Cantidad media por artículo"*, configurados con objetivos (targets) para medir el éxito de las estrategias de cross-selling.
- **Jerarquía de Inventario:** Un **Treemap** de artículos por unidades vendidas, apoyado por una tabla detallada de ventas, permite identificar de un vistazo los productos con mejor y peor desempeño.

5.2. Dashboard de Inteligencia de Cesta (Pág. 2)

Esta página traslada el modelo de probabilidad de Python al entorno visual, permitiendo explorar las **399 reglas de asociación**.

- **Explorador de Asociaciones (Force-Directed Graph):** Implementación de un gráfico de red interactivo donde el usuario selecciona un "Producto Antecedente" para visualizar sus conexiones con los "Consecuentes".
    - *Lógica Visual:* El grosor de las líneas de unión está vinculado al **Lift** calculado; a mayor correlación estadística, mayor impacto visual, permitiendo identificar oportunidades de venta cruzada de forma intuitiva.
- **Métricas de Calidad del Modelo:** En la cabecera se sitúan los indicadores de confianza del modelo: **Número de Reglas (399)**, **Confianza Media (8,3%)** y **Lift Medio (1,5)**.
- **Registro Detallado de Reglas:** Una tabla técnica ordenada por **Lift** permite a los especialistas de Marketing consultar la lista completa de las combinaciones de productos con mayor probabilidad de éxito comercial.

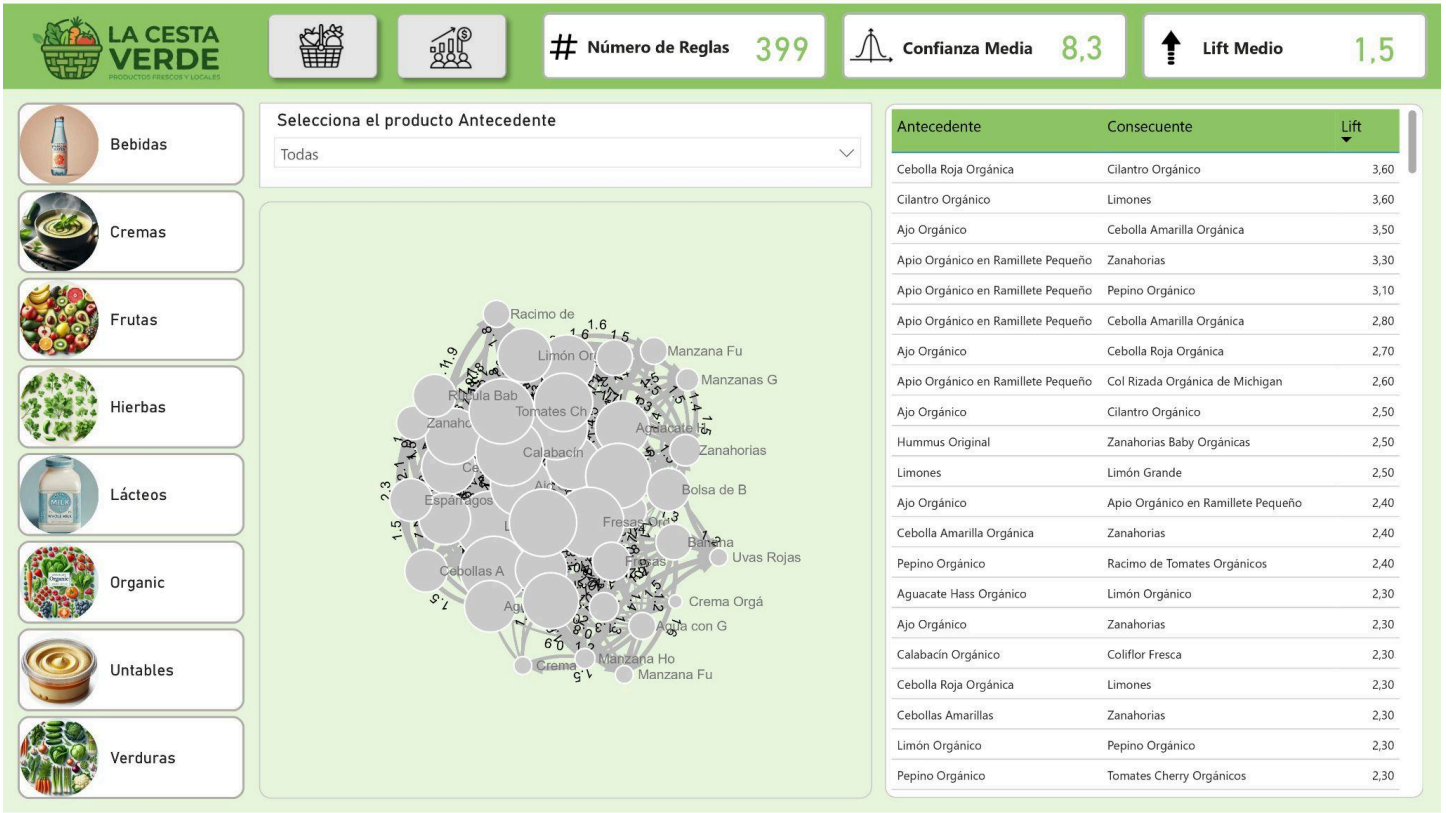

6. RESULTADOS, RECOMENDACIONES Y CONCLUSIÓN

El análisis técnico y la visualización de datos permitieron pasar de una fase de incertidumbre a una de acción estratégica. A continuación, se detallan los resultados obtenidos y la hoja de ruta propuesta para la gerencia de **La Cesta Verde**.

6.1. Resultados del Diagnóstico

- **Visibilidad Total:** Se ha logrado centralizar la información de más de **2 millones de transacciones**, permitiendo una auditoría en tiempo real de la facturación y el comportamiento del cliente.
- **Identificación de Patrones de Consumo:** El modelo de Python ha generado **399 reglas de asociación** validadas estadísticamente, eliminando las conjeturas en las decisiones de marketing y compras.

6.2. Recomendaciones Estratégicas (Plan de Acción)

Tras el diagnóstico realizado, se proponen tres ejes de actuación para revertir la tendencia decreciente de ingresos y fortalecer la resiliencia operativa de La Cesta Verde:

1. Estrategia de Diversificación y Mitigación de Riesgos

- **Acción:** Implementar campañas de promoción cruzada para impulsar los departamentos con baja rotación (Lácteos, Bebidas, Cremas) utilizando los productos "ancla" detectados en el análisis (Bananas y Fresas) como productos reclamo.
- **Fundamento Técnico:** El análisis de concentración reveló que el 93% de las ventas dependen de un solo departamento. Esta estrategia utiliza el flujo de clientes de productos líderes para traccionar las 3.800 referencias menos representadas.
- **Beneficio:** Reducir la dependencia crítica de los productos orgánicos y minimizar el impacto ante posibles fluctuaciones de oferta o demanda en las categorías dominantes.

2. Ampliación y Balance del Mix de Productos

- **Acción:** Introducir nuevas líneas de productos no orgánicos y fomentar la visibilidad de artículos menos populares mediante técnicas de *placement* (ubicación preferente).
- **Fundamento Técnico:** El análisis descriptivo evidenció una hiperconcentración en la categoría "Organic". Diversificar la oferta permite capturar nuevos segmentos de clientes con diferentes sensibilidades de precio.
- **Beneficio:** Atraer una base de clientes más amplia y adaptar el inventario a cambios en las preferencias del mercado, reduciendo el riesgo de obsolescencia de stock en secciones secundarias.

3. Optimización del Ticket Medio (AOV) mediante Inteligencia Analítica

- **Acción:** Integrar el motor de reglas de asociación generado en este proyecto dentro de la plataforma de e-commerce y en el sistema de cupones personalizados.
- **Fundamento Técnico:** Utilizar las 399 reglas de asociación calculadas. Por ejemplo, al detectar un Lift de 2,50 entre el *Hummus Original* y las *Zanahorias Baby*, el sistema debe automatizar la recomendación de este par, dado que su probabilidad de compra conjunta es un 150% superior a la media.
- **Beneficio:** Incrementar el ingreso medio por pedido (actualmente en **19,34 €**) y mejorar la retención del cliente mediante una experiencia de compra personalizada y eficiente.

4. Eficiencia Operativa y Logística (Slotting Estratégico)

- **Acción:** Reorganizar la disposición física de los productos en el almacén o lineales de tienda basándose en los clusters de afinidad detectados en el Force-Directed Graph.
- **Fundamento Técnico:** Las reglas de alto impacto (como la asociación Cilantro-Cebolla con Lift 3,60) dictan qué productos deben estar físicamente adyacentes.
- **Beneficio:** Agilizar el proceso de preparación de pedidos (*picking*), reducir costes operativos por desplazamiento y facilitar una navegación de compra más intuitiva para el usuario final.

6.3. Conclusión del Perfil

Este proyecto demuestra mi capacidad para gestionar el ciclo de vida completo del dato: desde la validación contable y auditoría SQL , pasando por el modelado estadístico en Python, hasta la comunicación estratégica en Power BI. Es la combinación de rigor financiero y analítica avanzada lo que permite transformar datos en rentabilidad.

Dashboard:
https://app.powerbi.com/reportEmbed?reportId=8a3bcad4-db59-4c3b-a33b-bf25370f0b6f&autoAuth=true&ctid=5f0e8993-efaa-4544-bb14-8ccacbf7d0be